

Detection of Changes in Sea Turtle Swimming Patterns for Defining Welfare Criteria

Naoto K. Inoue*

Abstract

ウミガメ保全の一環として、漂着・混獲個体の保護や孵化幼体のヘッドスタートが行われているが、その際にウミガメは制限された飼育環境下で大きな負の影響を受ける。それゆえ、飼育環境の福祉を評価する必要があるが、ウミガメに特化した福祉の評価法は確立していない。ウミガメでは、侵襲性や金銭的・人的コストの低さから行動観察による福祉評価が推奨されており、特にステレオタイプ行動(異常な反復行動)は福祉の貧しさを反映する指標になりうる。ステレオタイプ行動を評価するにはウミガメの遊泳パターンの変化を捉える必要があるが、繰り返しの遊泳パターンに関する定量的な指標は存在せず、ロバストな評価は困難である。それゆえ本研究では、動画からウミガメの輪郭形状の変化を時系列データとして抽出し、時系列解析を行うことで、遊泳パターンの変化を客観的に検出する手法を構築した。本研究の手法を試験的にアオウミガメの幼体に適用し、遊泳パターンの継続時間と変化を定量化した結果、(a) 漕ぎ運動と羽ばたき運動の相対的な割合、(b) 長期間にわたる特定の遊泳パターンの卓越、(c) グルーミングや底への執着といった行動の頻度、の3つを福祉指標として提案した。

Keywords : Conservation, Sea turtles, Shape analysis, Swimming pattern, Time-series analysis, Welfare

*Department of Science, Kobe University, Hyogo, Japan. Email:226s405s@cloud.kobe-u.jp

1 導入

ウミガメ個体群の多くが絶滅の危機に瀕しており [33]、さまざまな保全活動が行われている。特に、各地の水族館を中心として、漂着個体や混獲個体の保護・放流や、ヘッドスタートを目的とした幼体の飼育・放流が行われている。しかしこのとき、自然下では長距離を回遊しさまざまな環境刺激を受けるウミガメは [33]、人工的で狭く、刺激の少ない飼育環境において大きな負の影響を受ける [29, 32]。それゆえ、飼育環境の福祉をモニタリングし改善に努める必要があるが、既存の福祉指標は主に陸上動物を対象としたものであり、ウミガメに特化した福祉指標についてはほとんど議論されていない [1, 32]。

福祉評価の基準として、Mellor (2017) [16] は Five Domains (nutrition, environment, physical health, behaviour, mental) に注目することを提唱した。Five Domains の中でも、行動観察の利用はさまざまな動物に対して有益であると考えられている [30]。ウミガメに関しても、その他の domains の測定に困難が伴うため行動観察が推奨されている。具体的には、血液検査による physical health の評価は侵襲性や金銭的・人的コストが高く、体重測定による nutrition の評価は信頼性に欠け、environment は温度や湿度、水質といったさまざまな環境要因をモニタリングする必要がある評価自体が困難である。一方で、行動観察は侵襲性やコストが低く、さらに mental domain を内包するため、実用性が高い [1]。

行動観察によってウミガメの福祉を評価した研究では、福祉指標としてステレオタイプ行動が利用されている (e.g., [25, 9])。ステレオタイプ行動は、外部環境の制限による脳の機能障害を起因とする [15]、“反復的で変化に乏しく機能を持たない行動パターン” [11]、あるいは単純に“異常な反復行動” [2] のことであり、狭い空間や不適な温度条件といった福祉の貧しい環境下の動物において卓越することから [11, 12, 13]、福祉評価において最も有効な指標の一つである [10]。

行動による福祉評価を行う上では、観察者が一つのルールに基づき行動を計測することで客観性を担保する必要がある [30]。しかし、ウミガメのステレオタイプ行動の基準として提案されている、“Swimming in repetitive patterns around tank. Time began when the animal went into the third repeat of the behavior” [25]、や “Continuous, patterned repetition of a random, non-targeted behaviour” [32] といったものは非常に曖昧である。これらの曖昧さは福祉指標の

客観性を低下させるため、ウミガメの遊泳パターンを時系列データとして定量化した上で、パターン変化を検出する必要がある。

ウミガメの遊泳パターンを時系列データとして取得可能な手法としては、加速度計の装着が考えられる。加速度計は、自然下のウミガメの行動パターンを把握する目的で利用されており (e.g., [19, 34])、近年では機械学習を用いて加速度データから遊泳パターンを推定する試みもなされている [4]。しかし、多くの保護個体に対する加速度計の装着には高い金銭的・人的コストが必要となるだけでなく、着脱の行為自体がウミガメにストレスを与える [26]。すなわち、加速度計による福祉評価は、低いコスト・侵襲性という行動観察による福祉評価の利点を損なう可能性があるため、他の方法で時系列データを取得することが望ましい。

2次元動画は、行動に関する客観的なデータを提供することに加え [30]、スマホや監視カメラの普及によって低い金銭的・人的コストで取得可能であることから、多くの行動研究で利用されている (e.g., [7, 28])。特にウミガメは甲羅によって体の動きが制限されており、四肢の動きが移動や採餌において重要な役割を占めることから [35]、2次元動画に捉えられた四肢の動きは遊泳に関する多くの情報を含む。それゆえ本研究では、動画を用いてウミガメの遊泳パターンの変化を検出する手法を、以下の手順で構築する。

2.1 節: 水槽とウミガメとのコントラストを用いて動画から輪郭を抽出する

2.2 節: 抽出した輪郭に対し形状解析を適用することで四肢の動きを時系列データとして取得する

2.3 節: 取得した時系列データに対して VAR モデルに基づく時系列解析を行うことで遊泳パターンの変化を検出する

また、手法の構築に加え、構築した手法をアオウミガメの幼体に適用し、手法の利用可能性について議論した。

2 手法と材料

2.1 輪郭抽出

遊泳パターンを定量化するには、動画から四肢の動きを抽出する必要がある。このとき、機械学習を用いて四肢そのものをトラッキングすることが考えられるが、ウミガメは四肢の可動域が広く、2次元動画では頻繁に四肢のトラッキングが途切れてしまう。それゆえ本研究では、四肢の動きを捉えるために、動画の各フレームの輪郭形状を抽出することを考える。これは、ウミガメの甲羅が濃い色をしており、水槽の色とのコントラストによって特別な操作なしに輪郭が抽出可能なためである。実際には、動画を分割し作成した $i (= 1, 2, \dots, T)$ 番目のフレームの輪郭形状を、 P 個 (解析例では $R = 100$) の輪郭座標、

$$\mathbf{X}_{[i]} = (X_{[i,1]}, X_{[i,2]}, \dots, X_{[i,P]}), \quad \mathbf{Y}_{[i]} = (Y_{[i,1]}, Y_{[i,2]}, \dots, Y_{[i,P]}) \quad (1)$$

として得る。この輪郭抽出には python の findcontour 関数 [20] を使い、CE.py スクリプトに実装した。

抽出される輪郭座標は画像ごとに座標の番号付けが異なるため、画像同士を比較可能にする作業が必要である。ここでは、機械学習ソフト Deeplabcut [14] を用いて、トラックが途切れることのない項甲板 (頭に最も近い甲板) の端 A から臀甲板 (尾に最も近い甲板) の端 B をトラックし、これらの座標を用いて、xy 平面上で B の座標が (1,0)、A と B の中点の座標が (0,0) となるように輪郭座標の回転と規格化を行った (補足図 A.1 を参照のこと)。また、次節で述べる形状解析を行うには、ラベルと点の間隔を統一する必要があるため、R の approx 関数 [23] を用いて輪郭座標を直線近似したのち、尾の先端を始点として、各点の距離が等しくなるように輪郭座標を再設定した。このようにして、調整 (adjusted) した輪郭座標

$$\mathbf{x}_{[i]} = (x_{[i,1]}, x_{[i,2]}, \dots, x_{[i,P]}), \quad \mathbf{x}_{[i]} = (x_{[i,1]}, x_{[i,2]}, \dots, x_{[i,P]}), \quad (2)$$

を得ることができる。調節した輪郭座標のうち、ノイズの影響で xy 座標の絶対値が 2.5 を超えているものは欠損値とみなし、代わりに欠損していない 1 ステップ前の値を用いることでデータを補完した。これらの輪郭座標の規格化と調整は、FA.R スクリプトに実装した。

2.2 形状解析

形状解析は、閉じた物体の形状を定量化する手法であり、生物に対しては形態の比較を主な目的として利用されてきた (e.g., [17, 24])。形状解析は、輪郭形状に対する楕円フーリエ変換 [8] の適用と、取得したフーリエ係数に対する主成分分析 [3] の適用からなる。

まず、楕円フーリエ解析を輪郭座標 (2) に適用するため、座標に時刻 t_1, t_2, \dots, t_P を割り当て、 $t_P = 2\pi$ とする。これは、 x 座標と y 座標をそれぞれ閉じた波と捉えることに相当する。このとき、式 (2) の画像 i の $x_{[i,p]}$ と $y_{[i,p]}$ に対して、楕円フーリエ級数展開は、

$$\begin{aligned} x_{[i,p]} &= a_{\{i,0\}} + \sum_{n=1}^{\infty} (a_{\{i,n\}} \cos nt_p + b_{\{i,n\}} \sin nt_p) \\ y_{[i,p]} &= c_{\{i,0\}} + \sum_{n=1}^{\infty} (c_{\{i,n\}} \cos nt_p + d_{\{i,n\}} \sin nt_p) \end{aligned} \quad (3)$$

と書くことができる。ここで、 $a_{\{i,n\}}, b_{\{i,n\}}, c_{\{i,n\}}, d_{\{i,n\}}$ は画像 i における周期 n の楕円フーリエ係数である。本研究では四肢の動きを抽出するため、定数項 (すなわち $\cos 0$) の寄与を 0 とし、周期 1 以上の正弦波・余弦波の影響のみを考えることとした。これらの楕円フーリエ変換は、R パッケージ *stats* の `fft` 関数 [23] を用いて、FA.R スクリプトに実装した。

楕円フーリエ変換によって得ることのできる楕円フーリエ係数は有限個 (N 個とする: 解析例では $N = 40$) ではあるが、画像 i の形状は $4 \times N$ 次元の空間によって特徴付けられることになるため、その変化を直接解釈したり、時系列解析を適用することは困難である。それゆえ、主成分分析によって、楕円フーリエ係数の線形和から輪郭形状の変化をよく説明する新たな次元 (軸) に情報を圧縮することを考える。このとき、画像 i の楕円フーリエ係数を新たな軸へ射影することで得られる値 f_i を、

$$\begin{aligned} f_i &= w_{a1}a_{\{i,1\}} + w_{a2}a_{\{i,2\}} + \dots + w_{aN}a_{\{i,N\}} \\ &\quad + w_{b1}b_{\{i,1\}} + w_{b2}b_{\{i,2\}} + \dots + w_{bN}b_{\{i,N\}} \\ &\quad + w_{c1}c_{\{i,1\}} + w_{c2}c_{\{i,2\}} + \dots + w_{cN}c_{\{i,N\}} \\ &\quad + w_{d1}d_{\{i,1\}} + w_{d2}d_{\{i,2\}} + \dots + w_{dN}d_{\{i,N\}} \end{aligned} \quad (4)$$

とする。 $\mathbf{w} = (w_{a1}, \dots, w_{aN}, w_{b1}, \dots, w_{bN}, w_{c1}, \dots, w_{cN}, w_{d1}, \dots, w_{dN})$ は係数ベクトルであ

106 る。ここで新たに、 $(v_{\{i,1\}}, v_{\{i,1\}}, \dots, v_{\{i,4N\}}) = (a_{\{i,1\}}, a_{\{i,2\}}, \dots, d_{\{i,N\}})$ として、

$$s_{\{j,k\}} = \frac{1}{4N} \sum_{i=1}^{4N} (v_{\{i,j\}} - \bar{v}_j)(v_{\{i,k\}} - \bar{v}_k), \quad (5)$$

107 という共分散を考える。ここで、 \bar{v}_j, \bar{v}_k はそれぞれ $v_{\{i,j\}}, v_{\{i,k\}}$ の全ての画像に関する平均で
 108 ある。この共分散 $s_{\{j,k\}}$ を (j, k) 成分とする分散共分散行列 S を用いることで、新たに作成
 109 した軸上でのデータの分散は、

$$V_f = \mathbf{w}^T S \mathbf{w}, \quad (6)$$

110 と書くことができる。この分散を最大化する問題は、固有値を λ とする固有値問題、

$$S \mathbf{w} = \lambda \mathbf{w}, \quad (7)$$

111 に帰着する。

112 最も分散の大きな軸 (Principal Component 1; pc1) におけるデータの分散は最大固有値 λ_1
 113 に対応し、二番目に分散の大きな軸 (pc2) におけるデータの分散は二番目に大きな固有値 λ_2
 114 に対応する。このとき、例えばデータの分散のうち pc1 軸が説明する分散の値 (説明力) は、
 115 考慮する pc 軸の数が L 個のとき、

$$E_1 = \lambda_1 / (\lambda_1 + \lambda_2 + \dots + \lambda_L), \quad (8)$$

116 と表すことができる。また、各軸に対応する固有ベクトル \mathbf{w} は、楕円フーリエ係数の各軸に
 117 対する寄与度を表し、固有ベクトルと説明力の高い pc 軸の情報のみから復元した輪郭形状
 118 の視覚的なプロットを用いて、pc 軸の意味を解釈することができる。

119 これらの輪郭形状の主成分分析により、画像 i の輪郭形状が重要な pc 軸上での値 $(f_{1,i}, f_{2,i}, \dots)$
 120 によって表現される。例えば説明力が E_3 で急減する場合、画像の輪郭形状は2つの値 $(f_{1,i}, f_{2,i})$
 121 で特徴付けられるため、動画に捉えられた輪郭形状の変化を2次元時系列データ $\mathbf{f}_1 = f_{1,1}, f_{1,2}, \dots, f_{1,T};$
 122 $\mathbf{f}_2 = f_{2,1}, f_{2,2}, \dots, f_{2,T}$ として捉えることが可能になる。これらの主成分分析は、R パッケージ
 123 `stats` の `prcomp` 関数 [23] を用いて、PCA.R スクリプトに実装した。

2.3 時系列解析

2.1 節、2.2 節の手法によって取得した時系列を遊泳の特徴量と考え、その変化点の検出を行う。本研究では変化点の検出に、時系列モデリングに頻繁に用いられる AR (Auto Regressive) モデルを多変量に拡張した、VAR (Vector Auto Regressive) モデルを用いる。本研究で VAR モデルを用いる理由は 2 つある。1 つ目は、時系列同士の依存性を明示的に考慮すべきであるからだ。取得した時系列は時間方向には独立ではないため、時系列同士の依存性を考慮しなければ、動力的に重要な輪郭形状の変化を見逃す可能性がある。2 つ目は、時系列が持つ周期特性を捉えることのできるモデルを利用する必要があるからだ。輪郭形状の変化において、前肢の運動は振幅が大きく長い周期を持つ一方で、後肢は振幅が小さく周期は短い。それゆえ、取得した時系列には遊泳パターンごとに異なる周期成分が卓越すると考えられる。

n 次の VAR モデルは、 p 変量時系列ベクトル $f_t = (f_{1,t}, f_{2,t}, \dots, f_{p,t})$ に対して、

$$f_t = \sum_{m=1}^n \phi_m f_{t-m} + \epsilon_t, \quad (9)$$

と与えられる。ここで、 ϕ は $p \times p$ 係数行列であり、 ϵ は、平均 μ 、 $p \times p$ 共分散行列 Γ に従う多変量正規誤差である。VAR モデルは、

$$f = \begin{bmatrix} f_{n+1} \\ f_{n+2} \\ \vdots \\ f_T \end{bmatrix}, \quad Z = \begin{bmatrix} f_n & f_{n-1} & \cdots & f_1 \\ f_{n+1} & f_n & \cdots & f_2 \\ \vdots & \vdots & \ddots & \vdots \\ f_{T-1} & f_{T-2} & \cdots & f_{T-n} \end{bmatrix}, \quad \phi = \begin{bmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_n \end{bmatrix}, \quad \epsilon = \begin{bmatrix} \epsilon_{n+1} \\ \epsilon_{n+2} \\ \vdots \\ \epsilon_T \end{bmatrix} \quad (10)$$

を用いて、

$$f = Z\phi + \epsilon, \quad (11)$$

と書くことができる。この行列表現を用いて、VAR モデルの最尤推定値は、共分散行列の推定値 $\hat{\Gamma}$ の最小化、すなわち最小二乗法

$$\hat{\Gamma} = (Z^T Z)^{-1} Z^T f, \quad (12)$$

140 によって得ることができる。この p 変量 m 次 VAR モデルの対数尤度は、 $\Theta = \phi_1, \phi_2, \dots, \phi_m, \mu, \Gamma$
 141 とすると、

$$l(f | \Theta) = -p \times \frac{T-n}{2} (\log 2\pi + 1) - \frac{T-n}{2} \log |\hat{\Gamma}| \quad (13)$$

142 であり、AIC は、

$$\text{AIC}_m = \frac{1}{T-n} (-2 \times l(f | \hat{\Theta}) + 2 \times \text{parameter number}), \quad (14)$$

143 と与えられる。

144 VAR モデルを用いた時系列の分割では、任意の候補点で分割した際の AIC と、分割しな
 145 かった際の AIC を比較することで決定する。以下にそのアルゴリズムを示す。アルゴリズムの
 146 1 段階目では、区間パラメータ I を用いて、時系列の分割候補点を得る。ここでは、Kitagawa
 147 (2020) [6] の局所 AR モデルを参考とした。

148 1-1: 始点 $start$ から $candidate$ までの区間 $f_{start}, f_{start+1}, \dots, f_{candidate-1}$ の AIC_{sep1} と、 $candidate$
 149 から end までの区間 $f_{candidate+1}, f_{candidate+1}, \dots, f_{end-1}$ の AIC_{sep2} を計算し、これらの和
 150 $\text{AIC}_{sep} = \text{AIC}_{sep1} + \text{AIC}_{sep2}$ を計算する。

151 1-2: 始点 $start$ から end までの区間 $f_{start}, f_{start+1}, \dots, f_{end-1}$ の AIC_{int} を計算する。

152 1-3: AIC_{int} よりも AIC_{sep} が小さければ分割点として f_I を採用し、次の分割を行う始点とし
 153 て、 $Start$ を $candidate$ に更新し、候補点 $candidate$ は I に、終点 end は $2I$ に更新する。
 154 AIC_{int} よりも AIC_{sep} が大きければ、分割と始点の更新は行わないが、候補点 $candidate$
 155 を $candidate + I$ に更新し、終点 end を $end + I$ に更新する。

156 1-4: 1-1 から 1-3 を、 $start = 1$, $candidate = I$, $end = 2I$ の状態から繰り返すことで、時系
 157 列を区間長が I 以上の小区間に分離し、分割点 $(sep_1, sep_2, \dots, sep_P)$ を得る。

158 アルゴリズムの 2 段階目では、アルゴリズム 1 で分割した小区間の分割点の周りで、 $I_q (q =$
 159 $1, 2, \dots, Q)$ を用いて区切り、最適な分割点を決定する。

160 2-1: アルゴリズム 1 によって分割された $p-1$ 番目の点 sep_{p-1} と $p+1$ 番目の点 sep_{p+1} を、
 161 p 番目の点の周辺の点 $sep_p + I_q$ で区切り、分割後の AIC_q を計算する。

2-2: 2-1 を $1, 2, \dots, Q$ すべての周辺点に対して AIC_q を計算し、最も小さい AIC を持つものを新たな分割点とし、 sep_p をその分割点に更新する。

2-3: 2-1 から 2-2 を、 $p = 2, 3, \dots, P-1$ に対して繰り返し、分割点 $(sep_1, sep'_2, \dots, sep'_{P-1}, sep_P)$ を得る。

アルゴリズム 1 と 2 によって、計算コストを減らしつつ、VAR モデルを用いて時系列を定常区間に分割することが可能である。分割された区間は、異なる回帰係数によって特徴づけられる遊泳パターンを示していると解釈することができる。VAR モデルの推定と AIC の計算にはパッケージ *vars* の関数 VARselect と VAR [21] を用いて T.A.R スクリプトに実装した。

2.4 材料

サンプルデータの取得には、道の駅紀宝町ウミガメ公園 ($33^\circ 46'11''N$, $136^\circ 1'43''E$) のバックヤードにて、飼育下のアオウミガメ (年齢不明) の交配によって生まれた出生後 7 ヶ月の幼体 10 匹を用いた。これらの個体は、個体番号を 1 から 10 に対応するよう、Ekahi、Elua、Ekolu、Eha、Elima、Eono、Ehiku、Ewaru、Eiwa、Umi と名付けた (ハワイ語で 1 から 10 の数を表す)。幼体は水中ヒーター (テトラ社) によって 26 度に保たれた半球型ボウル (内径 24cm, 深さ 13.5cm) の中で飼育された。また、餌としてカメプロスプレミアム (キョーリン) と大きなカメの餌 (キョーリン) を 1 日に 1-2 回程度与え、毎日 1-2 回ボウルの水換えを行った。

幼体のうち 10 個体を用いて、図 1 の環境で実験を行った。実験時は、プラスチックケース ($29.7\text{cm} \times 48.2\text{cm} \times 15.0\text{cm}$) に水を満たし、その中にミニヒーター (テトラ社) を入れて 26 度に保った。半分程度を水で満たしたプラスチックケースの中に白色の半球型ボウル (内径 23cm, 深さ 13.5cm) を入れ、ボウルにはマリンソルト (GEX) を用いて塩分濃度を 20ppt にした水を入れた。各個体は 9 時にボウルに入れて 3 時間慣らしたのち、12 時から 13 時の間に防犯カメラ (safie 社) を用いて直上から動画を撮影した。データ取得終了後、各個体はもとの飼育環境に戻し、ボウルを水で洗浄した。

3 結果

2.1 節の手法を用いて、各個体から輪郭座標を抽出し規格化と回転を行った。動画 1-10 の左下には、各個体から抽出された輪郭形状の変化をプロットしている。光の反射によって輪郭形状が曖昧となったものが欠損値と判定され除外された。除外されたフレーム数は各個体の動画を構成するフレームの 1-3% を占めていた。

抽出した輪郭座標に対して、2.2 節の形状解析を実行し、すべての個体の輪郭形状から周期が 1 以上のフーリエ係数の線型結合からなる固有ベクトル、すなわち pc 軸を算出した。各 pc 軸の説明力を図 1 に示す。ここで、pc1 と pc2 のみで全体の 5 割程度の説明力があることと、pc1 と pc2 の値による平面上でのプロットの解釈性の高さから、以降はこれら 2 つの軸に注目する。

図 2 には pc1 と pc2 に対するフーリエ係数の寄与を示し、図 3 には pc1 と pc2 の値のみから復元した輪郭形状を示す。pc1 には x 座標の正弦成分と y 座標の余弦成分が寄与し pc2 には x 座標の余弦成分と y 座標の正弦成分が寄与することがわかり、復元した形状との対応から、pc1 として漕ぎ運動 (rowing) が抽出され、pc2 として羽ばたき運動 (flapping) が抽出されたと解釈することができる。動画 1-10 の右下には、輪郭形状の変化に対応した pc1 と pc2 の変化を図 3 に重ねてプロットしている。

形状解析によって取得した pc1 と pc2 に関する時系列に対し、2.3 節の VAR モデルに基づいた時系列解析を実行し、1 時間の時系列を小区間に分割した。このとき、ウミガメの遊泳は少なくとも 10 秒以上継続するものと仮定し、アルゴリズム 1 における区間パラメータを $I = 100$ と設定し、アルゴリズム 2 では $I_q = (-25, -20, -15, -10, -5, 0, 5, 10, 15, 20, 25)$ とした。分割された時系列を動画 1-10 の上に示す。

pc1 と pc2 がそれぞれ漕ぎ運動と羽ばたき運動を表していたことから、分割された区間を、(ptn1) 漕ぎ運動、(ptn2) 羽ばたき運動、(ptn3) ランダムな泳ぎ、(ptn4) その他、の 4 つのカテゴリに分類した。分類は目視によって行い、漕ぎ運動もしくは羽ばたきが時系列の 8 割以上を占めるものを ptn1 と ptn2 に、漕ぎ運動や羽ばたきのどちらも 8 割に満たず、遊泳に規則性が見られないものを ptn3 に分類した。そして、ptn1,2,3 のどれにも当てはまらないものを ptn4 に分類した。輪郭抽出の段階で、動画 1 は除外されたフレームが多く、動画 2 と 6 は前

肢が途切れるフレームが多かったことから、この分離は動画 3, 4, 5, 7, 8, 9, 10 に対してのみ行った。各個体に対し、分類した遊泳の継続時間の分布をバイオリンプロットとして図 4-10 の左に示した。また、各個体の遊泳パターンが占める割合と、その変化割合を図 4-10 の右にプロットした。

個体ごとの遊泳パターンの継続時間やその割合には個体間で大きな違いが見られた。特徴的なものをいくつか述べる。漕ぎ運動が遊泳時間に占める割合が最も大きかったのは ID9 で 25% であった。一方羽ばたきは ID7 と 8 で多くどちらの個体も 60% 以上であったが、その継続時間は 7 に比べて 8 の方が長い傾向にあった。ランダムな泳ぎは ID4, 9, 10 に卓越していたが、特に 4 は継続時間も長い傾向にあった。ptn4 には床への執着やグルーミング、後退などが含まれ、ID5 で最も卓越しており、遊泳パターンの 40% 以上を占めていた。

遊泳パターンの割合に関連して、その変化の割合にも個体間で大きな違いが見られた。例えば、羽ばたきとランダム遊泳の 2 種類が卓越する ID3 は 2 種類の遊泳を交互に繰り返すパターンの変化が多いのに対し、漕ぎ・羽ばたき・ランダム遊泳の 3 種が卓越する ID9 では、一度漕ぎから羽ばたきを経由してランダム遊泳がはじまるという変化の傾向がみられた。また、1 種類の遊泳パターンが卓越する ID4(ptn3), ID6(ptn4), ID7(ptn2), ID8(ptn2), ID10(ptn3) に関しては、卓越する遊泳パターンから他の遊泳パターンへの変化の割合は、その遊泳パターンが時間に占める割合に比例していた。

4 議論

本研究では、2 次元動画からウミガメの遊泳パターンの変化を検出する新たな手法を提案し、幼体のアオウミガメに適用することで解析例を示した。以下では本研究の手法を活用した展開を示す。

4.1 福祉指標の提案

本研究では、輪郭に対して形状解析を適用することで、遊泳を pc1 と pc2 の時系列データとして抽出した。pc1 と pc2 の変化に対応する漕ぎ運動と羽ばたき運動はカメ類の動力学に

において注目されてきた運動であるが、自然下においてリクガメや淡水ガメの主要な運動は漕ぎ運動であるのに対し、ウミガメの主要な運動は羽ばたき運動である [35]。一方、本研究で扱ったアオウミガメの幼体において、最も形状変化の説明力が高いものは漕ぎ運動であった (図 1)。また、ID9, 10 に関しては遊泳時間の 20% 程度を漕ぎ運動が占め、羽ばたきよりも遊泳時間に占める割合が多かった (図 4-10)。これらは、飼育環境における直線的な遊泳の制限によって、漕ぎ運動が卓越した結果であると考えられる。このことから、漕ぎ運動と羽ばたき運動の遊泳時間に占める割合は、飼育環境の狭さを反映する福祉指標となりうる。

ID4,7,8,10 は分類した中で特定の遊泳パターンが遊泳時間の半分以上を占めており、次の遊泳パターンを示すまでの継続時間も長かった。本研究で定義したランダム遊泳が正の福祉を示すか、あるいは負の福祉を示すかは明白ではないが、少なくとも漕ぎや羽ばたきの卓越は、遊泳パターンのバリエーションの少なさと関連し、負の福祉を表すと考えられる。特に羽ばたきの卓越は、本研究のような狭い環境下では壁に衝突したまま同じ方向に泳ぐことを意味するため、負の福祉を表すだろう。これらのことから、本研究の手法から定量化される羽ばたき運動の割合とその継続時間は福祉指標となりうる。

ptn4 に分類した遊泳パターンには、床への執着やグルーミング、後退などが含まれていたが、ID5 ではそれが占める割合が多く、継続時間も他の個体に比べて長かった。また遊泳速度は遅く、他の個体に比べて AIC によって選択された VAR モデルの次数が高い傾向にあった。ID5 の個体は、実験後の検査から細菌感染が発覚したため、実験当初は活力がなかったのだと考えられる。これらのことから、ptn4 の卓越は健康状態の悪化を反映する指標となりうる。

上記の議論から、本研究の手法を用いて定量化される (a) 漕ぎ運動と羽ばたきの比率、(b) 卓越する遊泳パターンの割合、(c) 異常行動 (ptn4) の割合と継続時間、の 3 つを福祉指標として利用できる可能性がある。

4.2 ロバストな福祉評価への指針

4.1 節で提示した指標を実用的なものにするため、3 つの指針を示す。1 つ目の指針は、機械学習手法を利用した輪郭抽出である。実際に解析を行う場合、動画の解像度や水槽、そし

て個体の大きさや種が異なることが想定される。これらの条件下では、影の写り込みやウミガメと水槽のコントラストの低下によって、輪郭抽出が失敗することが考えられる。このような場合には、コントラストや手動で抽出した輪郭を教師として学習を行い、学習に基づく輪郭抽出を行うことで、より精度の高い解析を行うことができる。

2つ目の指針は、クラスタリング手法の利用である。本研究の実験では試験的に、分割された時系列に対して目視による分類を行ったが、この際に介入する主観も排除すべきである。客観的な分類には、クラスタリング手法を用いることができる。本研究の時系列の分割にはVARモデルを仮定しているため、クラスタリングにはVARモデルをベースとした非類似度を用いる必要があるが、これは piccolo (1998) [22] や Kalpakis and Putagunta (2001) [5] らの非類似度を多次元に拡張することで対処できると考えられる。

3つ目の指針は、他の福祉指標との整合性の調査である。行動に基づく福祉評価はさまざまな利点を持つが、行動のみで福祉を判断することには危険が伴う [31]。それゆえ、本研究によって定量化される遊泳パターンの割合や継続時間と、ストレス指標であるコルチコステロンや健康指標であるグルコース濃度との関連性を調べることで、ロバストな福祉評価を行う必要がある。

4.3 個体レベルの福祉評価

遺伝や環境、経験、そして個性に応じて、同じ種であっても飼育下で受ける負の影響は個体ごとに異なるため、福祉評価は集団レベルではなく個体ごとに行うことが望ましい [30, 31]。本研究の実験は、同じ親から生まれ、同じ環境で育った幼体に対して行われたが、これらの個体が互いに異なる遊泳パターンの継続時間やその変化を示したことは (図 4-10)、福祉評価において個性を無視すべきではないことを示唆している。

しかし、個体レベルでの福祉評価では、個体ごとの基準に基づいて評価を行う必要がある。それゆえ、基準の解釈という段階で飼育員の主観が介入する集団レベルの評価に対して、個体レベルでの評価には、解釈に加え個体レベルの福祉基準を作成する段階においても主観が介入する。本研究の手法は、pc 軸の構築や時系列解析を集団レベルではなく個体レベルで行うことによって、この問題に対処することができる。さらに、集団レベルでの結果と個体レ

ベルでの結果を比較することで、個体レベルでの福祉評価自体の重要性について議論することも可能となる。

4.4 行動解析への応用

これまで、実験下のウミガメの行動に関する研究が行われてきたが、それらは福祉評価と似た課題を抱えている。例えば、ウミガメに対する海洋プラスチックや混獲の影響を議論するために、実験下で材質や色の異なる物体への応答や [18]、個体間での網への応答の違いが測定されてきたが [7]、これらの研究では、「選んだ材質や色の順位」や「網の近くで滞在した時間」といった指標によって応答が定量化された。これらの指標は行動の応答を十分に記述できない可能性がある。さらに、指標の数自体が少ないため、さまざまな行動応答の指標から個体差の大きいものを個性として定義する、というパーソナリティ心理学に基づく方法論 [27] を実行することができない。

本研究の手法では、遊泳パターンの変化に加え、対象の位置、方向も同時に取得可能である (動画を参照のこと)。それゆえ、これらの特徴量を用いて刺激への応答を詳細に記述することができる。例えば、刺激物に対する応答は、刺激物を提示した際の遊泳パターンの変化を示す pc1 や 2 の時系列と、距離と角度の時系列によって記述することが可能である。

Acknowledgement

I am grateful to Ito, S., Ishimoto, K., Yamamoto, Y., and Takehana, A., for collaboration in conducting the experiment at the Kiho Town Seaturtle Park, Mie, Japan. This research was funded by Frontier Development Division, Leave a Nest Co., Ltd., Shinjuku, Tokyo, Japan.

References

- [1] Diggins, R., Burrie, R., Ariel, E., Ridley, J., Olsen, J., Schultz, S., ... & Lloyd, J. (2022). A review of welfare indicators for sea turtles undergoing rehabilitation, with emphasis on environmental enrichment. *Animal Welfare*, 31(2), 219-230.

- [2] Garner, J. P. (2006). Perseveration and stereotypy-systems-level insights from clinical psychology. In *Stereotypic animal behaviour: fundamentals and applications to welfare* (pp. 121-152). Wallingford UK: Cabi.
- [3] Hotelling, H. (1936). Simplified calculation of principal components. *Psychometrika*, 1(1), 27-35.
- [4] Jeantet, L., Dell'Amico, F., Forin-Wiart, M. A., Coutant, M., Bonola, M., Etienne, D., ... & Chevallier, D. (2018). Combined use of two supervised learning algorithms to model sea turtle behaviours from tri-axial acceleration data. *Journal of Experimental Biology*, 221(10), jeb177378.
- [5] Kalpakis, K., Gada, D., & Puttagunta, V. (2001). Distance measures for effective clustering of ARIMA time-series. In *Proceedings 2001 IEEE international conference on data mining* (pp. 273-280). IEEE.
- [6] Kitagawa, G. (2020) *Introduction to Time Series Modeling with Applications in R*. Chapman & Hall/CRC.
- [7] Kudo, H., Nishizawa, H., Uchida, K., & Sato, K. (2021). Boldness–exploration behavioral syndrome in wild sub-adult green sea turtles caught at Oita, Japan. *Applied Animal Behaviour Science*, 236, 105216.
- [8] Kuhl, F. P., & Giardina, C. R. (1982). Elliptic Fourier features of a closed contour. *Computer graphics and image processing*, 18(3), 236-258.
- [9] Lloyd, J., Ariel, E., Adams, D., & Owens, L. (2012). Environmental enrichment for sea turtles in rehabilitation: Preliminary study
- [10] Maple, T. L., & Perdue, B. M. (2013). *Zoo animal welfare* (Vol. 14). Berlin, Germany:: Springer.
- [11] Mason, G. J. (1991). Stereotypies: a critical review. *Animal behaviour*, 41(6), 1015-1037.

- [12] Mason, G. J., & Latham, N. (2004). Can't stop, won't stop: is stereotypy a reliable animal welfare indicator?
- [13] Mason, G., Clubb, R., Latham, N., & Vickery, S. (2007). Why and how should we use environmental enrichment to tackle stereotypic behaviour?. *Applied Animal Behaviour Science*, 102(3-4), 163-188.
- [14] Mathis, A., Mamidanna, P., Cury, K. M., Abe, T., Murthy, V. N., Mathis, M. W., & Bethge, M. (2018). DeepLabCut: markerless pose estimation of user-defined body parts with deep learning. *Nature neuroscience*, 21(9), 1281-1289.
- [15] McBride, S. D., & Parker, M. O. (2015). The disrupted basal ganglia and behavioural control: an integrative cross-domain perspective of spontaneous stereotypy. *Behavioural brain research*, 276, 45-58.
- [16] Mellor, D. J. (2017). Operational details of the five domains model and its key applications to the assessment and management of animal welfare. *Animals*, 7(8), 60.
- [17] Neto, J. C., Meyer, G. E., Jones, D. D., & Samal, A. K. (2006). Plant species identification using Elliptic Fourier leaf shape analysis. *Computers and electronics in agriculture*, 50(2), 121-134.
- [18] Noh, H. J., Moon, Y., Shim, W. J., Cho, E. V., & Hong, S. H. (2024). Experimental study on color and texture as cues for plastic debris ingestion by captive sea turtles. *Marine Pollution Bulletin*, 200, 116055.
- [19] Okuyama, J., Kawabata, Y., Naito, Y., Arai, N., & Kobayashi, M. (2009). Monitoring beak movements with an acceleration datalogger: a useful technique for assessing the feeding and breathing behaviors of sea turtles. *Endangered Species Research*, 10, 39-45.
- [20] OpenCV Documentation. (2023). findContours. OpenCV.

- [21] Pfaff, B. (2008) Analysis of Integrated and Cointegrated Time Series with R. Second Edition. Springer, New York. ISBN 0-387-27960-1
- [22] Piccolo, D. (1990). A distance measure for classifying ARIMA models. *Journal of time series analysis*, 11(2), 153-164.
- [23] R Core Team. (2023). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. <https://www.R-project.org/>.
- [24] Rohlf, F. J., & Archie, J. W. (1984). A comparison of Fourier methods for the description of wing shape in mosquitoes (Diptera: Culicidae). *Systematic Zoology*, 33(3), 302-317.
- [25] Therrien, C. L., Gaster, L., Cunningham - Smith, P., & Manire, C. A. (2007). Experimental evaluation of environmental enrichment of sea turtles.
- [26] Thomson, J. A., & Heithaus, M. R. (2014). Animal-borne video reveals seasonal activity patterns of green sea turtles and the importance of accounting for capture stress in short-term biologging. *Journal of Experimental Marine Biology and Ecology*, 450, 15-20.
- [27] Uher, J. (2008). Comparative personality research: methodological approaches. *European Journal of Personality*, 22(5), 427-455.
- [28] Wang, J. H., Boles, L. C., Higgins, B., & Lohmann, K. J. (2007). Behavioral responses of sea turtles to lightsticks used in longline fisheries. *Animal Conservation*, 10(2), 176-182.
- [29] Warwick, C., Arena, P., Lindley, S., Jessop, M., & Steedman, C. (2013). Assessing reptile welfare using behavioural criteria. *In Practice*, 35(3), 123-131.
- [30] Watters, J. V., Margulis, S. W., & Atsalis, S. (2009). Behavioral monitoring in zoos and aquariums: A tool for guiding husbandry and directing research (Vol. 28, No. 1, pp. 35-48). Hoboken: Wiley Subscription Services, Inc., A Wiley Company.
- [31] Whitham, J. C., & Wielebnowski, N. (2013). New directions for zoo animal welfare science. *Applied Animal Behaviour Science*, 147(3-4), 247-260.

- 382 [32] Wood, L. D. (2022). Managing long-term wellness in captive sea turtles. *Animal Welfare*,
383 31(4), 423-432.
- 384 [33] Wyneken, J., Lohmann, K.J., & Musick, J.A. (Eds.). (2013). *The Biology of Sea Turtles*,
385 Volume 3 (1st ed.). CRC Press.
- 386 [34] Yasuda, T., & Arai, N. (2009). Changes in flipper beat frequency, body angle and swimming
387 speed of female green turtles *Chelonia mydas*. *Marine Ecology Progress Series*, 386, 275-
388 286.
- 389 [35] Zug, G. R. (1971). Buoyancy, locomotion, morphology of the pelvic girdle and hindlimb, and
390 systematics of cryptodiran turtles.




Figure 1: 輪郭形状の変化に対する各 pc 軸の説明力 E




Figure 3: pc1 と pc2 の情報のみを用いて pc 平面上に復元された輪郭形状




Figure 4: ID3 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)

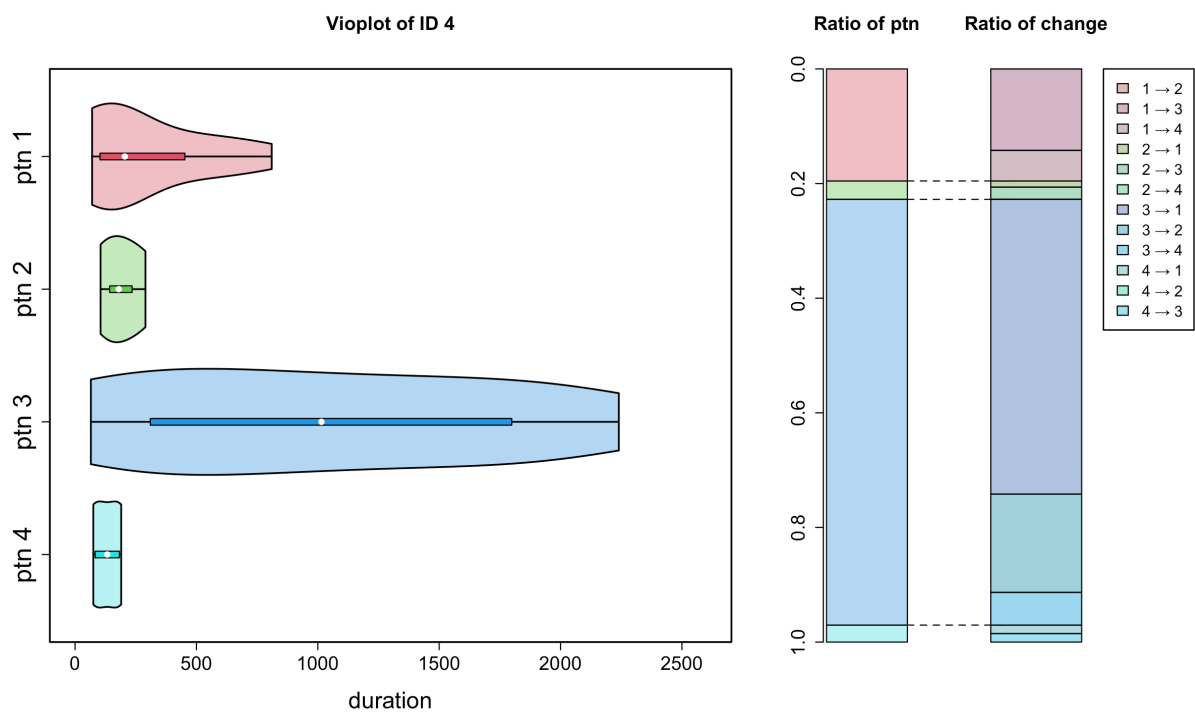


Figure 5: ID4 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)




Figure 6: ID5 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)




Figure 7: ID7 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)




Figure 8: ID8 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)




Figure 9: ID9 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)




Figure 10: ID10 の遊泳パターン 1-4 の継続時間に関するバイオリンプロットと箱ヒゲ図(左)。また、各遊泳パターンが 1 時間に占める割合(中)と異なる遊泳パターンへの変化の割合(右)